

Rapport de Mini-Projet : Apprentissage Supervisé Linéaire

Amanetullah Cheikh Mohamed Brahim (C22643)
Master 1 Intelligence Artificielle

Janvier 2026

1 Introduction

Ce rapport présente les travaux réalisés dans le cadre du module Machine Learning. L'objectif est de consolider les bases de l'apprentissage supervisé à travers l'implémentation et l'analyse de deux modèles fondamentaux : la Régression Linéaire pour la prédiction de variables continues et la Régression Logistique pour la classification binaire. L'intégralité du projet a été développée sous l'environnement **Google Colab**.

2 Méthodologie et Étapes de Réalisation

Le projet a été conduit selon un pipeline de science des données rigoureux, structuré en cinq étapes clés :

Configuration & Accès :

Environnement **Google Colab** avec montage du Drive et extraction automatisée des fichiers via `zipfile`.

Ingénierie des données :

Nettoyage, encodage des variables qualitatives (*Label Encoding*) et normalisation (*StandardScaler*) pour optimiser la convergence des modèles.

Entraînement :

Division des données en ensembles d'apprentissage (**80%**) et de test (**20%**) pour prévenir le sur-apprentissage.

Évaluation :

Validation des performances par les métriques R^2 et MSE pour la régression, ainsi que l'Accuracy et la matrice de confusion pour la classification.

3 Partie 1 : Régression Linéaire (Medical Insurance)

3.1 Choix et Préparation des Données

Nous avons utilisé le dataset *Medical Insurance Cost*. La variable cible est **charges**. Les variables catégorielles (sex, smoker, region) ont été encodées pour être intégrées dans l'équation mathématique du modèle.

3.2 Analyse des Corrélations

La matrice de chaleur (Figure 1) indique que la variable *smoker* est le facteur le plus corrélé aux coûts, suivie de l'âge et de l'IMC.




FIGURE 1 – Matrice de corrélation (Heatmap) montrant les facteurs influençant les charges.

3.3 Modélisation et Résultats

Le modèle est formalisé par : $y = \beta_0 + \sum \beta_i x_i + \epsilon$. Les performances obtenues après évaluation sont : $R^2 = 0.7833$ et $MSE = 33\,596\,915.8$.

3.4 Interprétation des Coefficients β_i

L'impact majeur est porté par la variable **smoker** ($\beta = 23593.98$), confirmant que le tabagisme augmente drastiquement les frais médicaux, suivi par l'IMC et l'âge.

4 Partie 2 : Régression Logistique (Iris Dataset)

4.1 Choix et Préparation des Données

Pour cette partie, nous avons utilisé le dataset **Iris** (natif dans Scikit-Learn). Le problème a été transformé en une classification binaire : distinguer la classe *Iris-Setosa* (Classe 0) des autres espèces. Les données ont été normalisées pour garantir une convergence optimale du modèle.

4.2 Modélisation et Performance

La probabilité est calculée via la fonction sigmoïde : $P(y = 1|x) = \frac{1}{1+e^{-z}}$. Le modèle obtient une **Accuracy de 100%**. Ce résultat s'explique par la séparabilité linéaire claire de la classe Setosa par rapport aux autres.

4.3 Matrice de Confusion

La matrice confirme l'absence totale d'erreurs (Vrais Négatifs : 20, Vrais Positifs : 10).




FIGURE 2 – Matrice de confusion - Classification binaire Iris.

5 Conclusion

Ce projet démontre l'efficacité des modèles linéaires. La Régression Linéaire a permis de quantifier l'impact du mode de vie sur les coûts d'assurance, tandis que la Régression Logistique a prouvé sa robustesse pour la classification de données linéairement séparables.